

PROYECTO CIENCIA DE DATOS

INTEGRANTES: Milenka Guerra
SECCIÓN: 002D
DOCENTE: Mariela Moraga

INDICE.

Contenido

INDICE.....	1
INTRODUCCIÓN.....	2
DESARROLLO.....	3
Fase 1: Comprensión del Problema o Negocio.....	3
Fase 2: Comprensión de los datos.....	3
Fase 3: Preparación de los datos.....	3
Fase 4: Modelado.....	3
Fase 5: Evaluación del modelo.....	3
Fase 6: Implementación.....	3
Trabajo colaborativo en Git/GitHub.....	4
CONCLUSIONES.....	5
BIBLIOGRAFIA.....	6

INTRODUCCIÓN.

El presente informe documenta el desarrollo del examen transversal de la asignatura “Programación para la Ciencia de Datos” (SCY1101), cuyo propósito es aplicar de manera integrada los conocimientos adquiridos durante el semestre en un proyecto de ciencia de datos end-to-end.

El proyecto aborda el análisis del dataset Car Seats, que contiene información de ventas de sillas para niños en 400 tiendas, junto con características de precio, publicidad, ubicación en estantería y del entorno socioeconómico de cada tienda. El objetivo general es construir una solución completa que permita comprender qué factores influyen en el desempeño comercial de una tienda y anticipar si sus ventas serán altas o bajas, apoyando así la toma de decisiones de negocio.

Para ello, se desarrolla un pipeline ETL que integra el dataset original con una API externa de tipo de cambio, con el fin de estandarizar en pesos chilenos (CLP) las columnas expresadas originalmente en dólares. Sobre los datos transformados se realiza un análisis exploratorio, se construye un dashboard interactivo con Plotly Dash para comunicar hallazgos de negocio, y se entrenan y comparan dos modelos supervisados de clasificación, Regresión Logística y Random Forest, para predecir la variable objetivo HighSales. Adicionalmente, se documenta el análisis de arquitecturas de datos (Lambda, Lakehouse y Pipeline Híbrido Modular) y una investigación sobre el uso de Docker en ciencia de datos, y se versiona todo el desarrollo mediante repositorios con Git y GitHub.

Este informe presenta el trabajo siguiendo la metodología CRISP-DM (Cross Industry Standard Process for Data Mining), describiendo en cada una de sus fases las decisiones tomadas, los hallazgos obtenidos y su justificación técnica.

DESARROLLO.

CRISP-DM (Cross Industry Standard Process for Data Mining) es una metodología estándar para el desarrollo de proyectos de ciencia de datos, estructurada en seis fases iterativas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación e implementación. Su relevancia radica en que ordena el trabajo técnico en torno a un objetivo de negocio concreto, evitando que el análisis se convierta en un ejercicio puramente exploratorio sin relación con la toma de decisiones. En este informe, CRISP-DM se utiliza como hilo conductor para documentar de manera trazable cada decisión tomada en el proyecto Car Seats, desde la obtención de los datos hasta la implementación del modelo final y su comunicación mediante un dashboard interactivo.

La integración de diversas fuentes de datos es un componente central del proyecto, ya que, además del archivo `dataset_car_seats.csv`, se incorpora una API REST de tipo de cambio para convertir a pesos chilenos las columnas monetarias originalmente expresadas en dólares. Combinar fuentes de distinta naturaleza, un archivo estático y un servicio web consultado en tiempo de ejecución, es representativo de escenarios profesionales reales, donde rara vez toda la información requerida está disponible en un único origen, y exige diseñar mecanismos de resiliencia ante fallas de conectividad o disponibilidad de las fuentes externas.

Fase 1: Comprensión del Problema o Negocio.

El problema de negocio abordado es la falta de un criterio sistemático para anticipar qué tiendas de la cadena tendrán un desempeño de ventas alto o bajo, lo que dificulta priorizar decisiones comerciales como la inversión en publicidad, la mejora de la ubicación del producto en la estantería o los ajustes de precio.

El objetivo general del proyecto es desarrollar una solución de ciencia de datos que permita estandarizar y explorar la información disponible de las 400 tiendas del dataset Car Seats, identificar qué variables se asocian de forma más clara con el nivel de ventas, y construir un modelo predictivo capaz de clasificar si una tienda tendrá ventas altas o bajas, mediante la variable objetivo `HighSales`, definida como ventas superiores a 8 mil unidades. Como objetivo secundario, se busca comunicar estos hallazgos mediante un dashboard interactivo que permita a un perfil de negocio explorar la relación entre las variables y las ventas.

Fase 2: Comprensión de los datos.

La comprensión de los datos comenzó con la obtención de información desde dos fuentes distintas. Una es el archivo `dataset_car_seats.csv`, con 400 registros y 11 columnas relativas a ventas, precios, publicidad, población, edad promedio, escolaridad y ubicación del producto. La otra es una API REST de tipo de cambio, utilizada para convertir a pesos chilenos las columnas `CompPrice`, `Income`, `Advertising` y `Price`, originalmente expresadas en dólares. Se evaluaron las dos APIs sugeridas en el enunciado: `dolarapi.com` respondió de forma rápida y con un formato simple, mientras que `mindicador.cl` no respondió dentro del tiempo de espera considerado en las primeras pruebas realizadas, por lo que se definió a `dolarapi.com` como fuente principal, con `mindicador.cl` como respaldo ante una falla, y un valor fijo, congelado al 1 de julio de 2026, como última instancia de contingencia si ambas conexiones fallaran.

Antes de cualquier transformación se validó la integridad del dataset, sin encontrarse valores nulos ni registros duplicados en ninguna de las 400 filas, por lo que no fue necesario aplicar imputación. De las 11 columnas originales, `ShelveLoc`, `Urban` y `US` son categóricas, mientras que el resto son numéricas. Las estadísticas descriptivas mostraron que `Sales` tiene una distribución simétrica (media y mediana de 7,5 mil unidades), que en promedio la empresa cobra menos que la competencia (`Price` promedio de \$105.923 CLP frente a \$114.321 CLP de `CompPrice`), y que `Advertising` presenta asimetría hacia la derecha (mediana de \$4.574 CLP, por debajo de su media de \$6.069 CLP), reflejando que una proporción importante de tiendas no invierte en publicidad local. La detección de outliers mediante el criterio de rango intercuartílico (IQR) identificó una cantidad marginal de casos atípicos, 2 en `Sales`, 2 en `CompPrice` y 5 en `Price`, sobre 400 registros, consistentes con tiendas de condiciones legítimamente extremas y no con errores de captura.

El análisis de correlación mostró que `Price` es la variable con mayor asociación, en valor absoluto, con `Sales` (-0,44), seguida de `Advertising` (+0,27) y `Age` (-0,23), mientras que `Income`, `CompPrice`, `Population` y `Education` presentan correlaciones débiles. Entre las variables categóricas, `ShelveLoc` resultó ser, por lejos, la más asociada a las ventas: la proporción de tiendas con ventas altas pasa de 15% en tiendas con ubicación `Bad`, a 38% en `Medium` y 78% en `Good`, mientras que `Urban` y `US` mostraron diferencias más moderadas. Estos hallazgos orientaron las expectativas sobre qué variables serían más relevantes en la etapa de modelado.

Fase 3: Preparación de los datos.

La preparación de los datos comenzó con la transformación de las cuatro columnas monetarias, CompPrice, Income, Advertising y Price, reemplazando directamente su valor en dólares por el equivalente en pesos chilenos obtenido de la API de tipo de cambio, redondeado a peso entero. Se excluyeron de esta conversión las columnas Sales y Population porque, si bien son numéricas, no representan montos monetarios sino cantidades de unidades y de personas, respectivamente. Sobre los datos ya convertidos se creó la variable objetivo HighSales, que toma el valor 1 si las ventas de la tienda superan las 8 mil unidades, o 0 en caso contrario, resultando en una distribución de 236 tiendas con ventas bajas (59,0%) y 164 con ventas altas (41,0%).

Previo a la construcción de los modelos se aplicaron transformaciones adicionales, por ejemplo, la variable ShelfLoc, de 3 niveles, se codificó mediante One-Hot Encoding eliminando la primera categoría para no introducir redundancia entre las columnas dummy resultantes, mientras que Urban y US, binarias, se codificaron directamente como 0 y 1. La variable Sales se excluyó del conjunto de predictores, ya que HighSales se calculó directamente a partir de ella y mantenerla habría generado fuga de información hacia el modelo.

El escalado de las variables numéricas, mediante StandardScaler, no se aplicó de forma independiente antes de dividir los datos, sino dentro del Pipeline de cada modelo, evitando así que el conjunto de prueba influyera en los parámetros de escalado. Respecto a los valores atípicos identificados mediante el criterio IQR, se decidió no tratarlos ya que representan menos del 1,3% de los datos y no corresponden a errores de captura. Además, los modelos seleccionados, Regresión Logística regularizada y Random Forest, son razonablemente robustos frente a este nivel de outliers.

Fase 4: Modelado.

Los datos se dividieron en conjuntos de entrenamiento y prueba, en una proporción de 80% y 20% respectivamente, utilizando el parámetro stratify sobre la variable HighSales para preservar la proporción 59/41 en ambos conjuntos, y una semilla aleatoria fija para asegurar la reproducibilidad del experimento. Esta división es necesaria para evaluar el desempeño del modelo sobre datos que no participaron en su entrenamiento, evitando así una estimación optimista de su capacidad de generalización.

Se entrenaron dos modelos supervisados de clasificación binaria para predecir HighSales. El primer modelo fue una Regresión Logística, elegida por su interpretabilidad y por servir

de línea base lineal, y el segundo fue un Random Forest, un modelo de ensamble capaz de capturar relaciones no lineales entre las variables. Ambos modelos se implementaron dentro de un Pipeline de scikit-learn que integra el escalado de variables y el clasificador, y se optimizaron utilizando la misma técnica de búsqueda de hiperparámetros, GridSearchCV, con validación cruzada de 5 folds, para asegurar una comparación justa entre ambos. La búsqueda mostró que la Regresión Logística obtuvo el mejor F1-score en validación cruzada (0,85), por encima del Random Forest (0,77), resultado que se explica porque las variables más predictivas identificadas en el EDA (ShelveLoc, Price y Advertising) presentan relaciones bastante lineales o monótonas con HighSales, un patrón que un modelo lineal regularizado logra capturar eficientemente, mientras que, al tratarse de un dataset pequeño y limpio, el ensamble no logra aprovechar plenamente su mayor flexibilidad.

Como métricas de evaluación se utilizaron accuracy, F1-score, precision, recall y ROC-AUC. Se priorizó F1-score y ROC-AUC por sobre accuracy dado que, si bien las clases están razonablemente equilibradas (59% y 41%), estas métricas entregan una visión más completa del desempeño del modelo sobre cada clase, en particular sobre la clase de interés para el negocio, HighSales = 1.

Fase 5: Evaluación del modelo.

En el conjunto de prueba, compuesto por 80 tiendas, ambos modelos alcanzaron un desempeño alto, aunque con diferencias relevantes por clase. La Regresión Logística obtuvo un accuracy de 0,91: sobre las 47 tiendas de ventas bajas acertó en 43, y sobre las 33 de ventas altas acertó en 30, con un recall de 0,91 y una precision de 0,93. El Random Forest alcanzó un accuracy de 0,86, con el mismo resultado que la Regresión Logística sobre la clase de ventas bajas, pero un desempeño notoriamente menor sobre la clase de ventas altas, acertando solo 26 de 33 casos (recall 0,79), es decir, dejando pasar 7 tiendas de ventas altas como si fueran bajas.

Al comparar ambos modelos de forma consolidada, la Regresión Logística fue seleccionada como el modelo final, con un F1-score de 0,90 y un ROC-AUC de 0,98 en el conjunto de prueba, por sobre el F1 de 0,83 y el ROC-AUC de 0,94 del Random Forest. Esta ventaja se mantuvo consistente entre la validación cruzada y el conjunto de prueba, lo que descarta que se trate de un resultado casual asociado a una única división de los datos. La curva ROC confirmó visualmente este resultado, ya que la curva de la Regresión Logística domina casi todo el rango sobre la del Random Forest, manteniéndose cercana a la esquina superior izquierda del gráfico. Para efectos de negocio, la diferencia más relevante está en

el recall sobre la clase de ventas altas. Un recall más alto en la Regresión Logística, 0,91 frente a 0,79, significa identificar correctamente a más tiendas con buen desempeño potencial, en lugar de pasarlas por alto.

El análisis de importancia de variables confirmó, con evidencia del modelo, los hallazgos del análisis exploratorio. Las columnas Price (coeficiente -3,76), ShelfLoc_Good (coeficiente +2,97) y Advertising (coeficiente +1,87) resultaron ser las tres variables más influyentes en ambos modelos. Un hallazgo adicional, no evidente en el análisis univariado, fue la relevancia de CompPrice (coeficiente +2,52), pese a su correlación débil con Sales (0,06), su efecto solo se revela al controlar simultáneamente por Price, lo que indica que, para un precio propio fijo un competidor más caro constituye una ventaja competitiva relativa. Este resultado ejemplifica cómo el modelado multivariado puede revelar relaciones que el análisis exploratorio variable por variable no logra capturar.

Fase 6: Implementación.

Entre los principales insights de negocio identificados, destaca que las tiendas con buena ubicación en estantería (ShelveLoc = Good) venden en promedio casi el doble que las de ubicación mala, que las tiendas más baratas que la competencia alcanzan un 56% de ventas altas frente a solo un 16% en las más caras, y que invertir en publicidad alta casi duplica la probabilidad de ventas altas, 61% frente a 31% sin publicidad. Estos hallazgos son consistentes con los coeficientes obtenidos en el modelo de Regresión Logística y permiten priorizar acciones concretas como mejorar la ubicación del producto, revisar la posición de precio respecto a la competencia, e invertir en publicidad allí donde hoy es baja o nula.

Para comunicar estos hallazgos se construyó un dashboard interactivo con Plotly Dash, embebido directamente en el notebook mediante `app.run(jupyter_mode="inline")`, que levanta el servidor en un hilo de fondo sin bloquear la ejecución de las secciones siguientes. El dashboard se organiza en dos vistas: una Vista Ejecutiva, orientada a un perfil de negocio, que presenta cuatro indicadores clave (número de tiendas, ventas promedio, ingreso total estimado en CLP y porcentaje de tiendas con ventas altas) junto con tres gráficos acompañados de una conclusión de negocio en lenguaje simple. Y una Vista Analítica, pensada para exploración libre, que permite filtrar por ShelfLoc, Urban o US y observar cómo cambian las ventas, la proporción de ventas altas y bajas, y la relación entre precio y ventas según la categoría seleccionada.

Trabajo colaborativo en Git/GitHub.

El proyecto se versionó utilizando Git y GitHub siguiendo un flujo de trabajo basado en ramas por etapa. Cada fase del desarrollo, ETL, EDA, dashboard y modelos, se implementó en su propia rama (feature/etl, feature/eda, feature/dashboard y feature/modelos), integradas de forma incremental hacia la rama develop antes de consolidarse en main. Posteriormente, las correcciones solicitadas sobre la evaluación 3 pasada se gestionaron también en ramas independientes (fix/manejo-nulos, fix/dashboard y docs), cada una con sus propios commits descriptivos, lo que permite trazar de forma clara el historial de cambios y aislar cada corrección sin afectar el resto del proyecto.

CONCLUSIONES.

El dataset Car Seats llegó completo, sin valores nulos ni registros duplicados, lo que permitió que el ETL se concentrara en su tarea central de poder convertir cuatro columnas monetarias de dólares a pesos chilenos mediante una API externa, y construir la variable objetivo HighSales, con una distribución de 59% de ventas bajas y 41% de ventas altas, sin desbalance severo. El análisis exploratorio identificó a ShelfLoc como la variable más asociada a las ventas, con una diferencia amplia entre categorías (78% de ventas altas en tiendas con buena ubicación frente a 15% en las de mala ubicación), y a Price y Advertising como predictores secundarios pero consistentes.

La Regresión Logística superó al Random Forest en todas las instancias de evaluación, validación cruzada, conjunto de prueba y curva ROC, un resultado distinto al patrón habitual en que los modelos de ensamble suelen superar a los lineales, explicado por la naturaleza mayormente lineal de las relaciones entre las variables más predictivas y el tamaño reducido y limpio del dataset. El hallazgo más relevante del proyecto fue el rol de CompPrice, invisible en el análisis univariado (correlación de 0,06 con Sales) pero relevante en el modelo multivariado, lo que evidenció el valor de combinar análisis exploratorio y modelado para descubrir relaciones que no son evidentes a simple vista. Como principales limitaciones del proyecto se identifican el tamaño reducido de la muestra (400 tiendas, 80 en el conjunto de prueba), el uso de un umbral de clasificación por defecto (0,5) sin ajustarlo al costo de negocio de cada tipo de error, y la no incorporación explícita de la interacción entre Price y CompPrice como variable derivada, lo que constituye una mejora directa para una futura iteración del proyecto.

BIBLIOGRAFIA.

- dolarapi.com. (2026). API de cotizaciones de divisas.
<https://cl.dolarapi.com/v1/cotizaciones/usd>
- mindicador.cl. (2026). API de indicadores económicos de Chile.
<https://mindicador.cl/api>
- Plotly Technologies Inc. (2024). Dash Documentation. <https://dash.plotly.com/>
- Docker Inc. (2024). Docker Documentation. <https://docs.docker.com>